МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
по курсу
«Data Science Pro»

на тему:
«Прогнозирование конечных свойств новых материалов (композиционных материалов)»

Слушатель Котляров Артем Владимирович

Москва, 2024

Содержание

Введение	3
1. Аналитическая часть	4
1.1 Постановка задачи	4
1.2. Описание используемых методов	5
1.3. Разведочный анализ данных	7
2. Практическая часть	11
2.1. Предобработка данных	11
2.2. Разработка и обучение модели	16
2.3. Тестирование модели	18
2.4. Описание нейронной сети	22
3. Вывод	

Введение

Композиционные материалы (композиты) — это материалы, состоящие, как минимум, из двух компонентов с разными свойствами. Наиболее популярные из них — полимерные. Они включают в себя армирующий наполнитель (стеклянное или углеродное волокно с определенным плетением и технологией производства) и связующее вещество — например, полиэфирную или эпоксидную смолу.

Композиты обладают теми свойствами, которые не наблюдаются у компонентов по отдельности. При этом композиты являются монолитным материалом, т. е. компоненты материала неотделимы друг от друга без разрушения конструкции в целом.

Композиционные материалы применяются для различных задач: производство корпуса судна, крыла самолета, высоконагруженных деталей агрегатов.

Однако при разработке композитов возникают различные проблемы. Одной из них является сложность оценки и предсказания различных характеристик композита, даже в случае, если известны исходные компоненты, из которых предполагается создать композиционный материал.

На данный момент имеется серьезный запрос на программное моделирование свойств композиционных материалов, т.к. это поможет сократить количество различных опытов и испытаний, а также пополнить базу данных материалов возможными новыми характеристиками материалов, и цифровыми двойниками новых композитов, что позволит эффективно прогнозировать прочностные характеристики и поведение композитов.

Развитие методов моделирования поведения композитных материалов с учетом их структуры на различных уровнях организации позволят оптимизировать их сопротивление разрушению, прочность, текучесть, износостойкость и иные параметры.

1. Аналитическая часть

1.1 Постановка задачи

Задачей данной работы является определение упругих и прочностных характеристик нового композиционного материала. Для решения задачи требуется:

1) Разработать и обучить алгоритм машинного обучения, который по заданным входным значениям переменных будет определять следующие характеристики композитов:

- Модуль упругости при растяжении в гигапаскалях (ГПа);
- Прочность при растяжении в мегапаскалях (МПа).

2) Разработать нейронную сеть, которая на основе полученных данных будет прогнозировать рекомендованное соотношение «матрица-наполнитель» для состава композита.

3) Разработать приложение, которое будет выдавать прогнозные значения, полученные в результате выполнения данного задания.

Исходные данные к задаче представлены двумя файлами в табличном формате Microsoft Excel с различными характеристиками нового материала. Данные файлы были объединены в единый датасет со следующими характеристиками:

- Количество входных переменных – 12;
- Количество выходных переменных – 3;
- Генеральная совокупность наблюдений – 1023;
- Объем выборки наблюдений – 940;
- Обнаруженных пропусков в генеральной совокупности – 0;
- Обнаруженных выбросов в генеральной совокупности – 83.

В 12 столбцах объединенного файла данные имеют формат числа с плавающей точкой (float64) и данные в одном столбце «Угол нашивки, град.» представлены в формате целого числа (int).

1.2. Описание используемых методов

В задаче определены 3 выходные переменные, из которых две должны определяться моделью машинного обучения. По итогам отбора моделей были выбраны две модели: SGDRegressor и SVRegressor.

1) SGDRegressor. Регрессор стохастического градиентного спуска (SGD) в основном реализует простую процедуру обучения SGD, поддерживающую различные функции потерь и штрафы для соответствия моделям линейной регрессии.

Преимущества:

– Эффективность: для снижения потребности в одновременном сохранении и обработке всего набора данных, алгоритм постепенно обновляет параметры модели для каждой точки данных или небольшого пакета.

– Масштабируемость: наборы данных, которые могут не полностью поместиться в памяти, могут обрабатываться с помощью SGD. Он может работать с большими и потоковыми источниками данных, обрабатывая данные по частям или небольшими пакетами.

– Регуляризация: различные методы регуляризации, включая L1 (lasso), L2 (ridge) и elasticnet, легко адаптируются SGD.

– Устойчивость к шуму: устойчив к зашумленным данным.

Недостатки:

– Чувствительность к настройкам: алгоритм может при неправильной конфигурации демонстрировать медленную конвергенцию или даже дивергенцию. Выбор правильной скорости обучения и точная настройка гиперпараметров имеют решающее значение.

– Локальные минимумы: SGD может оказаться в локальном минимуме и не гарантируется, что глобальный минимум функции потерь будет найден.

– Чувствительность к порядку данных: расположение точек данных обучения может сильно повлиять на процедуру обучения и производительность модели.

2) SVRegressor – это тип алгоритма регрессии, который использует машины опорных векторов (SVM) для изучения функции, которая наилучшим образом предсказывает непрерывное выходное значение для данного входного значения. SVR может использовать как линейные, так и нелинейные ядра. Выбор ядра зависит от характеристик данных и сложности задачи.

Преимущества:

– Нечувствительность к размеру данных: может работать с данными как большого, так и небольшого размера.

– Метод опорных векторов эквивалентен двухслойной нейронной сети, где число нейронов на скрытом слое определяется автоматически как число опорных векторов.

– Принцип оптимальной разделяющей гиперплоскости приводит к максимизации ширины разделяющей полосы, а следовательно, к более уверенному решению задач.

Недостатки:

– Неустойчивость к шуму: выбросы в обучающих данных становятся опорными объектами-нарушителями и напрямую влияют на построение разделяющей гиперплоскости.

– Не описаны общие методы построения ядер и спрямляющих пространств, наиболее подходящих для конкретной задачи.

– Необходимость подбора константы C при помощи кросс-валидации.

Для нахождения третьей переменной в соответствии с заданием была разработана многослойнная нейронная сеть.

3) Многослойная нейронная сеть – математическая модель, а также их программные или аппаратные реализации, построенные по принципу организации и функционирования биологических нейронных сетей — сетей нервных клеток живого организма.

Преимущества:

– Мощный инструмент — может быть использован для широкого класса задач.

– Высокая обобщающая способность — может находить сложные закономерности и паттерны в данных.

– При правильной настройке может выдавать высокую точность и превосходить многие другие алгоритмы, а в определенных задачах даже людей.

Недостатки:

– Требует очень много данных для обучения.

– Очень сложно интерпретировать полученные результаты. Нет четких критериев, чтобы понять, почему нейронная сеть приняла определенное решение.

– Очень дорогое обучение: чем сложнее задача, тем больше данных требуется и тем дольше модель учится.

1.3. Разведочный анализ данных.

В рамках разведочного анализа данных изучен датасет, полученный слиянием двух таблиц Microsoft Excel в один датафрейм. Первичное изучение проводилось методами .info() и .describe().

```
composed_mat.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1023 entries, 0 to 1022
Data columns (total 13 columns):
 #   Column                             Non-Null Count  Dtype  
---  ------                             --------------  -----  
 0   Соотношение матрица-наполнитель    1023 non-null   float64
 1   Плотность, кг/м3                   1023 non-null   float64
 2   модуль упругости, ГПа              1023 non-null   float64
 3   Количество отвердителя, м.%        1023 non-null   float64
 4   Содержание эпоксидных групп,%_2    1023 non-null   float64
 5   Температура вспышки, С_2           1023 non-null   float64
 6   Поверхностная плотность, г/м2      1023 non-null   float64
 7   Модуль упругости при растяжении, ГПа  1023 non-null   float64
 8   Прочность при растяжении, МПа      1023 non-null   float64
 9   Потребление смолы, г/м2            1023 non-null   float64
 10  Угол нашивки, град                 1023 non-null   int64  
 11  Шаг нашивки                        1023 non-null   float64
 12  Плотность нашивки                  1023 non-null   float64
dtypes: float64(12), int64(1)
memory usage: 111.9 KB
```

Рисунок 1 – Результат работы метода .info()

```
composed_mat.describe()
```

	Соотношение матрица-наполнитель	Плотность, кг/м3	модуль упругости, ГПа	Количество отвердителя, м.%	Содержание эпоксидных групп,%_2	Температура вспышки, С_2	Поверхностная плотность, г/м2	Модуль упругости при растяжении, ГПа	Прочность при растяжении, МПа	Потребление смолы, г/м2	Угол нашивки, град	Шаг нашивки	Плотность нашивки
count	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000
mean	2.930366	1975.734888	739.923233	110.570769	22.244390	285.882151	482.731833	73.328571	2466.922843	218.423144	44.252199	6.899222	57.153929
std	0.913222	73.729231	330.231581	28.295911	2.406301	40.943260	281.314690	3.118983	485.628006	59.735931	45.015793	2.563467	12.350969
min	0.389403	1731.764635	2.436909	17.740275	14.254985	100.000000	0.603740	64.054061	1036.856605	33.803026	0.000000	0.000000	0.000000
25%	2.317887	1924.155467	500.047452	92.443497	20.608034	259.066528	266.816645	71.245018	2135.850448	179.627520	0.000000	5.080033	49.799212
50%	2.906878	1977.621657	739.664328	110.564840	22.230744	285.896812	451.864365	73.268805	2459.524526	219.198882	0.000000	6.916144	57.341920
75%	3.552660	2021.374375	961.812526	129.730366	23.961934	313.002106	693.225017	75.356612	2767.193119	257.481724	90.000000	8.586293	64.944961
max	5.591742	2207.773481	1911.536477	198.953207	33.000000	413.273418	1399.542362	82.682051	3848.436732	414.590628	90.000000	14.440522	103.988901

Рисунок 2 – Результат работы метода .describe()

По результатам изучения полученных сведений о датасете, установлено, что пропуски в данных отсутствуют, все данные представлены в числовых форматах (float64, int). Также выявлены минимальные и максимальные значения в каждом столбце средние значения, первый, второй и третий квантили, стандартные отклонения.

Был построен комбинированный график парных зависимостей для визуализации отношений переменных.

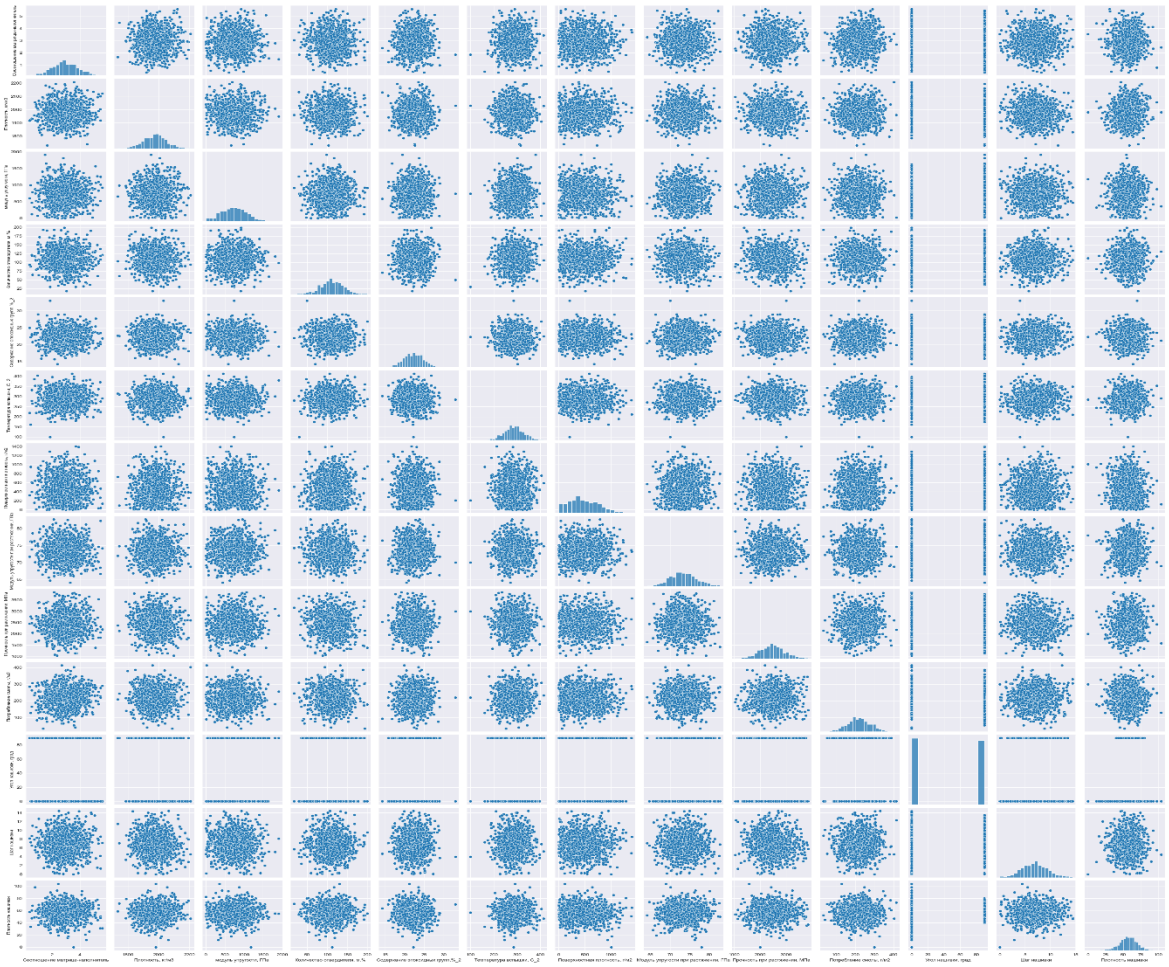


Рисунок 3 – График парных зависимостей

Общего взгляда достаточно, чтобы сделать вывод о том, что переменные в датасете линейно практически не связаны и имеют случайный разброс. При этом на центральной оси выведены распределения переменных и можно предположить, что они нормально распределены.

Для выявления корреляции между переменными, были построены матрицы корреляции с использованием методов Пирсона и Спирмена. Сравнение коэффициентов корреляции поможет выявить не только линейную связь, но и нелинейную. Построенные матрицы корреляции были преобразованы в более информативные тепловые карты при помощи библиотеки Seaborn. Для удобства и наглядности сформированы отдельные тепловые карты корреляции с целевыми переменными.



Рисунок 4 – Корреляция с модулем упругости при растяжении

При сравнительном рассмотрении можно увидеть, что между некоторыми переменными есть очень слабая, незначительная корреляция с околонулевыми значениями коэффициентов.

Уточним состояние данных и проверим наличие выбросов. Выбросы удобно определять на диаграмме BoxPlot, на которой отображаются все

квантили, наибольшие и наименьшие значения, которые не считаются выбросами и сами выбросы.

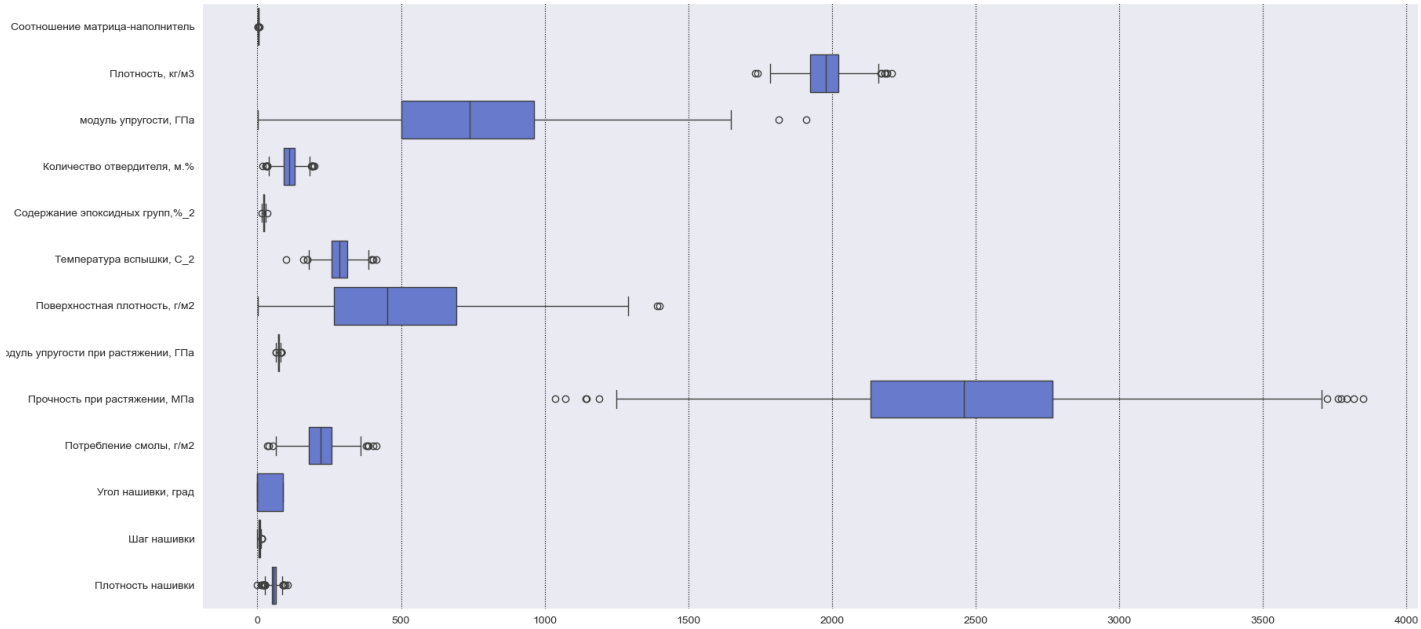


Рисунок 5 – Обнаружение выбросов на диаграмме BoxPlot

В текущем состоянии выбросы имеются, в том числе и среди значений целевых переменных.

Учитывая, что данные имеют исчезающе малую связь между собой, необходимо определить какие переменные значимы, а какие нет. Для этого проанализируем данные с помощью метода главных компонент из состава библиотеки sci-kit learn и выведем результат в датафрейм.

	Cumulative Variance Ratio	Explained Variance Ratio
0	0.539692	0.539692
1	0.788055	0.248363
2	0.968885	0.180830
3	0.981266	0.012381
4	0.989434	0.008168
5	0.994027	0.004593
6	0.997832	0.003806
7	0.999610	0.001777
8	0.999948	0.000338
9	0.999970	0.000022
10	0.999985	0.000015
11	0.999998	0.000013
12	1.000000	0.000002

Рисунок 6 – Результат анализа методом главных компонент

В результате анализа можно сделать вывод о том, что 99,7% дисперсии данных может быть объяснено семью переменными. Остальные переменные объясняют только 0,3% дисперсии.

При этом, если ограничиться только переменными с вкладом более 1%, то в этом случае может быть объяснено 98,1% дисперсии всего четырьмя переменными.

Исходя из данных предпосылок, можно смело утверждать, что, оставив 4-6 признаков мы практически не потеряем информацию в датасете.

2. Практическая часть

2.1. Предобработка данных

Рассмотрим гистограммы распределений переменных:

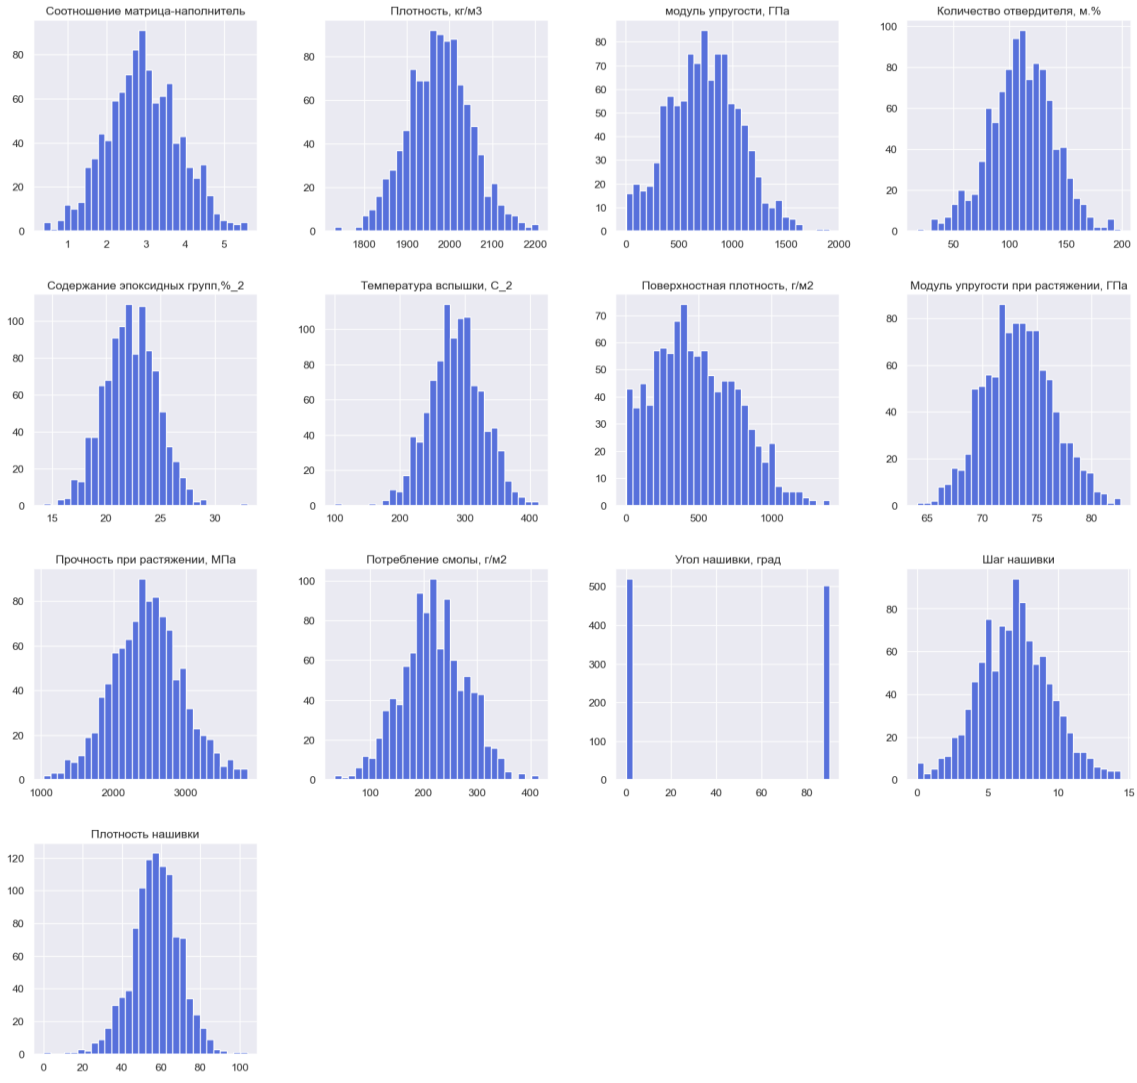


Рисунок 7 – Распределение переменных

У большинства переменных имеются незначительные отклонения от нормального распределения.

Далее проводим нормализацию данных через класс Normalizer библиотеки sci-kit learn. Этот класс по умолчанию проводит нормализацию строк, а не столбцов, приводя данные в строках к диапазону от 0 до 1.

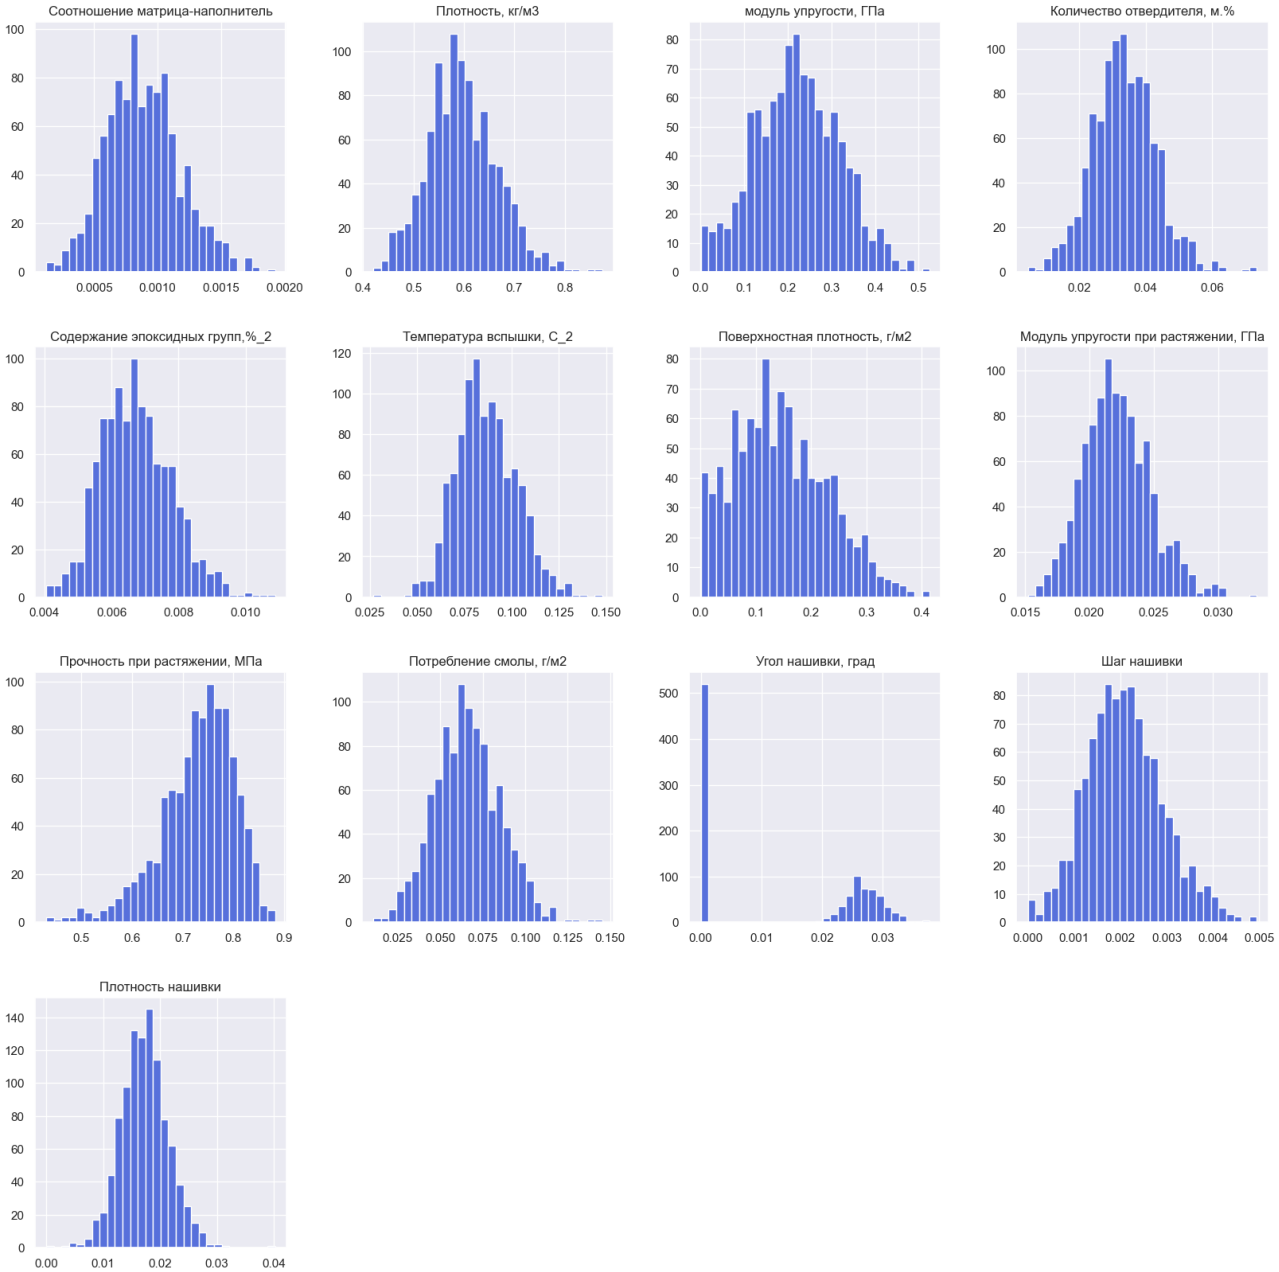


Рисунок 8 – Данные после нормализации классом Normalizer

Теперь проводим чистку от выбросов методом zscore библиотеки scipy. Для этого обозначим, что выбросы – это значения, которые не входят в 3 стандартных отклонения относительно среднего значения. В результате применения метода было удалено 37 выбросов.

После удаления выбросов проведем перемасштабирование данных в диапазоне от 0 до 1, применив для этого MinMaxScaler. В результате переменные датасета пришли к следующему состоянию:

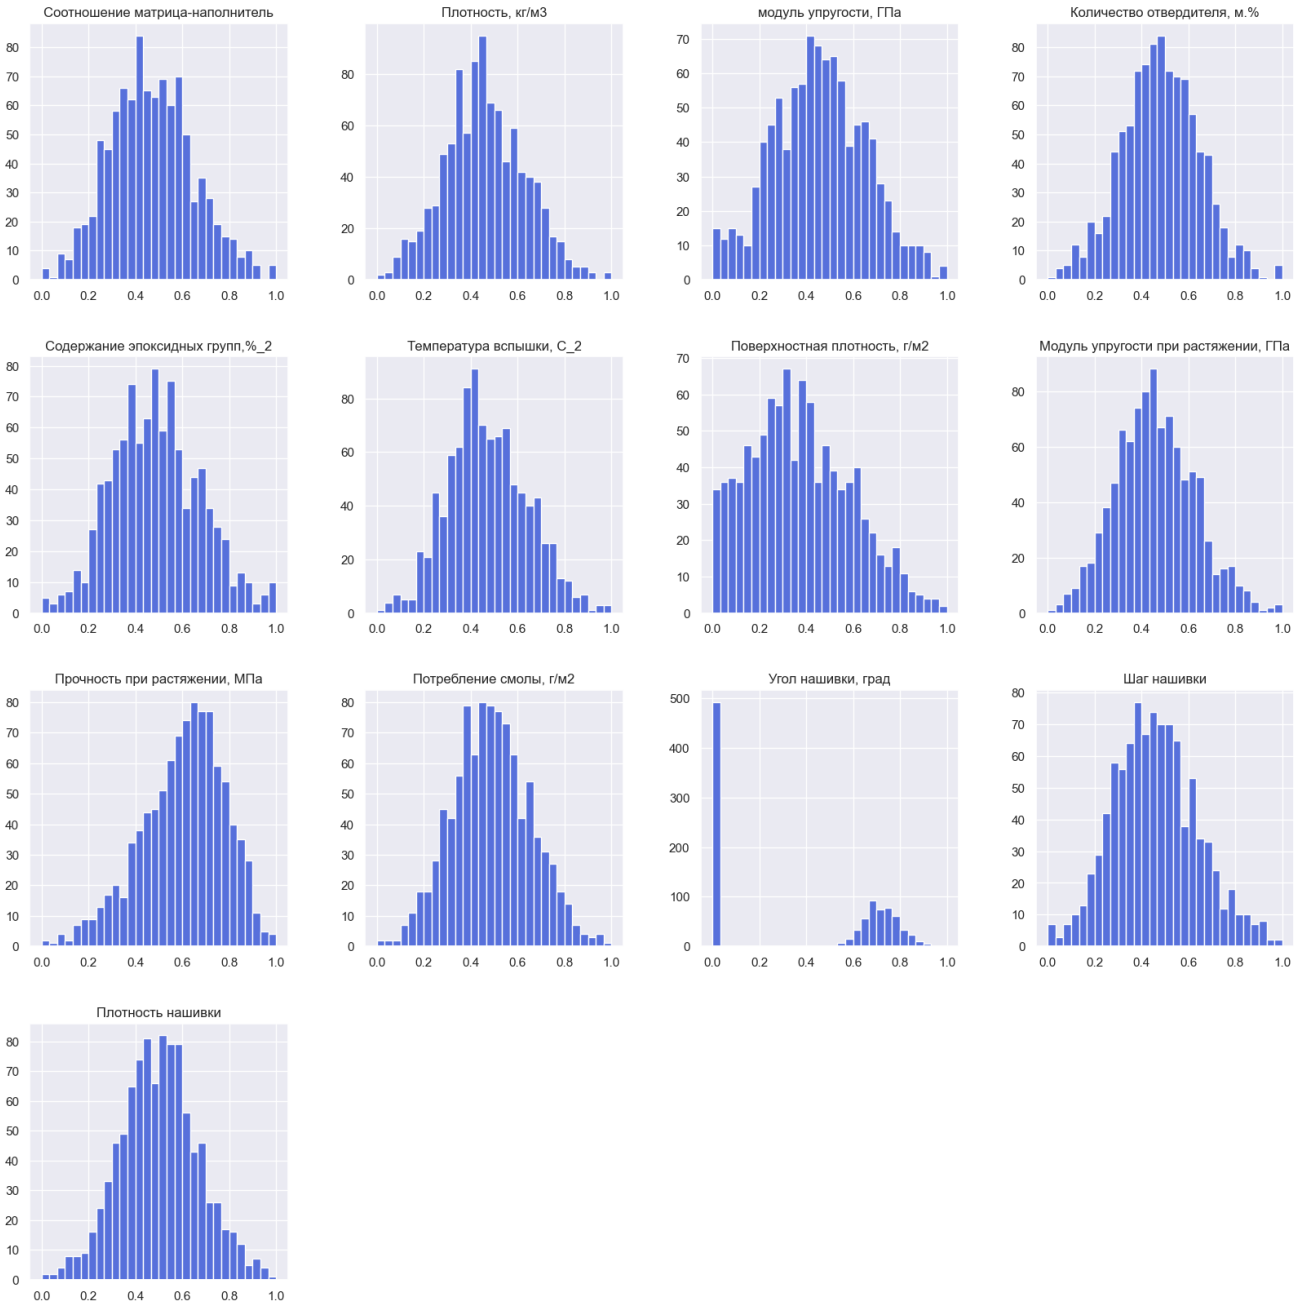


Рисунок 9 – Данные после масштабирования MinMaxScaler

Исходя из полученных гистограмм, в датасете еще сохраняются выбросы, которые можно зачистить методом межквартильного размаха. Оставшиеся выбросы можно отсечь, определив для удаления значения, лежащие за пределами диапазона 1,5 IQR от медианного значения.

В результате применения метода выявлено и удалено еще 46 выбросов. Таким образом в общей сложности выявлено и удалено 83 выброса.

У некоторых моделей машинного обучения существенно снижается качество работы, если при подготовке датасета данные не были стандартизированы. Для чего выполним стандартизацию данных с помощью StandardScaler. После стандартизации значения переменных выглядят следующим образом:

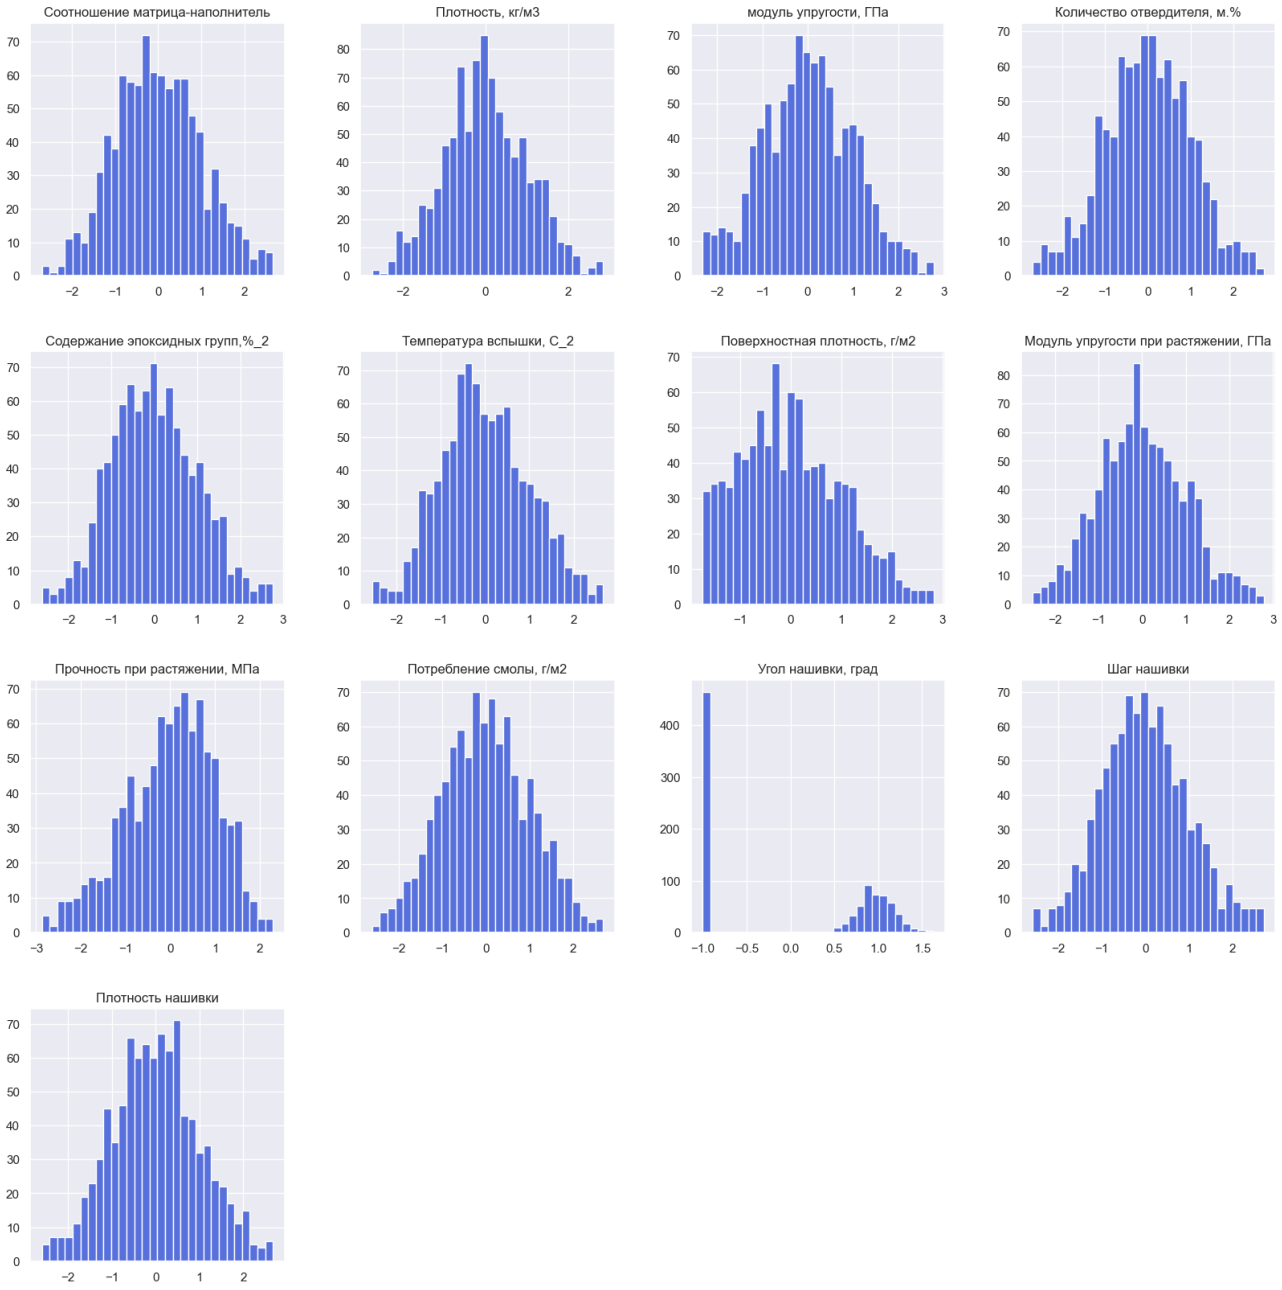


Рисунок 10 – Данные после стандартизации

Для визуальной оценки данных после всех операций, связанных с выявлением и удалением выбросов, построим диаграмму BoxPlot.

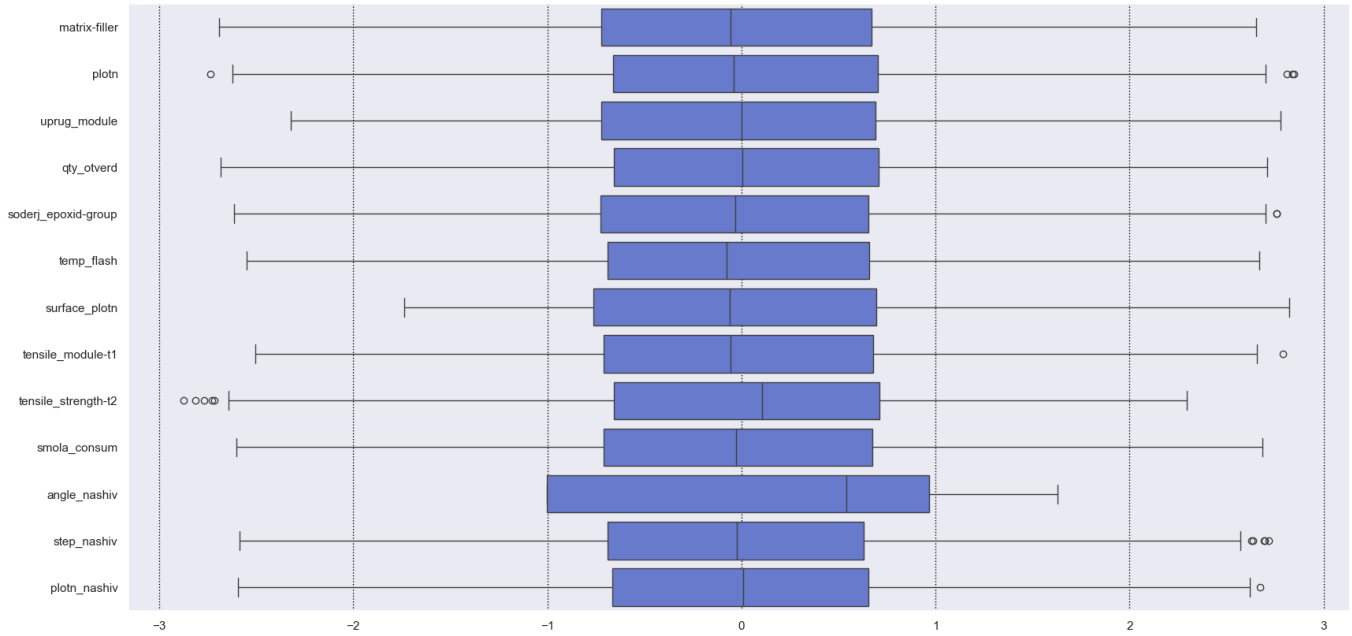


Рисунок 11 – Переменные после чистки выбросов и стандартизации

В данных остались некоторые выбросы в пределах от 2,5 до 2 стандартных отклонений, однако это не критично. Датасет готов к подготовке для обучения модели.

Распределение минимальных и максимальных значений признаков сложилось в соответствии с рисунками 12, 13:

1) Минимумы и максимумы до нормализации:

```
Максимумы значений до нормализации: Соотношение матрица-наполнитель          5.591742
Плотность, кг/м3                         2207.773481
модуль упругости, ГПа                    1911.536477
Количество отвердителя, м.%               198.953207
Содержание эпоксидных групп,%_2            33.000000
Температура вспышки, С_2                  413.273418
Поверхностная плотность, г/м2            1399.542362
Модуль упругости при растяжении, ГПа       82.682051
Прочность при растяжении, МПа            3848.436732
Потребление смолы, г/м2                   414.590628
Угол нашивки, град                         90.000000
Шаг нашивки                                14.440522
Плотность нашивки                         103.988901
dtype: float64

Минимумы значений до нормализации: Соотношение матрица-наполнитель          0.389403
Плотность, кг/м3                         1731.764635
модуль упругости, ГПа                       2.436909
Количество отвердителя, м.%                17.740275
Содержание эпоксидных групп,%_2            14.254985
Температура вспышки, С_2                  100.000000
Поверхностная плотность, г/м2               0.603740
Модуль упругости при растяжении, ГПа       64.054061
Прочность при растяжении, МПа            1036.856605
Потребление смолы, г/м2                    33.803026
Угол нашивки, град                          0.000000
Шаг нашивки                                 0.000000
Плотность нашивки                           0.000000
dtype: float64
```

Рисунок 12 – Максимальные и минимальные значения признаков до нормализации

2) Минимумы и максимумы после стандартизации:

```
Максимумы значений после стандартизации: Соотношение матрица-наполнитель        2.650514
Плотность, кг/м3                          2.848606
модуль упругости, ГПа                     2.776424
Количество отвердителя, м.%               2.707300
Содержание эпоксидных групп,%_2           2.757822
Температура вспышки, С_2                  2.668775
Поверхностная плотность, г/м2             2.822008
Модуль упругости при растяжении, ГПа      2.790750
Прочность при растяжении, МПа             2.293827
Потребление смолы, г/м2                   2.685044
Угол нашивки, град                        1.629224
Шаг нашивки                               2.717862
Плотность нашивки                         2.671510
dtype: float64

Минимумы значений после стандартизации: Соотношение матрица-наполнитель       -2.691352
Плотность, кг/м3                         -2.736077
модуль упругости, ГПа                    -2.323349
Количество отвердителя, м.%              -2.684268
Содержание эпоксидных групп,%_2          -2.614614
Температура вспышки, С_2                 -2.548547
Поверхностная плотность, г/м2            -1.738038
Модуль упругости при растяжении, ГПа     -2.506112
Прочность при растяжении, МПа            -2.872854
Потребление смолы, г/м2                  -2.602050
Угол нашивки, град                       -1.002024
Шаг нашивки                              -2.584298
Плотность нашивки                        -2.595601
dtype: float64
```

Рисунок 13 – Максимальные и минимальные значения признаков после стандартизации

2.2. Разработка и обучение модели

При рассмотрении возможных моделей для работы с имеющимися данными, внимание уделялось, в первую очередь, возможности модели работать с нелинейными данными. При подборе кандидатов также учитывалась устойчивость к выбросам и шуму.

Для применения в качестве моделей для прогноза целевых переменных рассматривалось четыре алгоритма регрессии:

1) Регрессор стохастического градиентного спуска (SGDRegressor);
2) Регрессор машины опорных векторов (SVR);
3) XGBoost Regressor;
4) GradientBoostingRegressor.

Алгоритмы градиентного бустинга на небольших валидационных наборах не смогли показать стабильную и бессбойную работу. В связи с чем, их пришлось

исключить из дальнейшей работы. Работа была продолжена с моделями SVR и SGDRegressor.

Для разработки и обучения модели прогнозирования переменной «Модуль упругости при растяжении» датасет был разделен. Целевая переменная выделена в отдельный массив y_labels1, независимые переменные в массив X_features1. В массив с независимыми переменными были отобраны признаки в соответствии с результатами анализа методом главных компонент.

Все переменные в целях упрощения работы с кодом были переименованы в названия на латинице.

Для включения отбирались признаки имевшие наибольшие коэффициенты корреляции с целевым признаком. Было отобрано шесть переменных, из которых одна, в последствии, была исключена.

Окончательный вариант наборов данных до обучения модели в соответствии с рисунком 14:

X_features1

	plotn	qty_otverd	soderj_epoxid-group	surface_plotn	smola_consum
0	-0.713087	-2.218974	-0.257871	-1.055939	-0.326567
1	-0.713665	-2.222148	2.254532	-1.055984	-0.326779
2	-0.719975	0.206541	-0.941562	-1.056477	-0.329091
3	-0.722912	-0.321108	-0.667264	-1.056706	-0.330168
4	-0.812878	-0.305155	-0.639200	-1.053509	-0.315158
...	...	...	...	...	...
935	0.194608	-0.689071	-0.440399	-0.957749	-1.453622
936	0.842327	1.470698	-0.508550	-0.404768	-1.545492
937	-0.268160	-0.082513	0.326294	0.880994	0.199831
938	1.212125	1.444487	-0.454284	0.773639	-0.093594
939	-0.937713	0.400000	1.101248	0.860905	-0.564618

940 rows × 5 columns

y_labels1

```
0     -1.298964
1     -1.299484
2     -1.305154
3     -1.307793
4     -1.270992
         ...
935    0.267660
936    0.392909
937   -0.075613
938    0.807226
939   -0.418823
Name: tensile_module-t1, Length: 940, dtype: float64
```

Рисунок 14 – Наборы данных для обучения

Каждый набор был поделен на обучающую, тестовую и валидационную выборки методом test_train_split. В процентном отношении наборы данных были сформированы следующим образом:

1) Обучающие данные – 60%;
2) Тестовые данные – 20%;
3) Валидационные данные – 20%.

Таким образом размер каждого набора составил:

1) Исходный набор – 940 наблюдений;
2) Обучающий набор – 564 наблюдения;
3) Тестовый набор – 188 наблюдений;
4) Валидационный набор – 188 наблюдений.

Дополнительно, для упрощения подбора гиперпараметров, была разработана функция отчета для метода случайного подбора гиперпараметров RandomizedSearchCV.

С целью наиболее эффективного подбора гиперпараметров модели, была сформирована цепочка функций подбора и проверки гиперпараметров, организованная по принципу каскада.

Аналогичный подход к делению данных и организации подбора гиперпараметров предусмотрен и для модели прогнозирования второй переменной «Прочность при растяжении».

2.3. Тестирование модели

Проведены следующие этапы обучения:

1) Кросс-валидация (перекрестная проверка);
2) Обучение;
3) Проверка.

Для оценки работы алгоритмов использовался метод оценки R2_score, вычисляющий коэффициент детерминации (R^2), а также среднеквадратичная ошибка (RMSE), средняя абсолютная ошибка (MAE), средняя квадратическая ошибка (MSE).

1) Определение модуля упругости при растяжении:

– Модель: SGDRegressor;

– Лучшие гиперпараметры: loss='squared_error', penalty='elasticnet', alpha=0.1, l1_ratio=0.45, max_iter=2000, shuffle=True, epsilon=0.0001, random_state=60, learning_rate='constant', eta0=0.1;

– Оценка R2 при перекрестной проверке: 0,661;

– Оценка R2 после обучения: 0,758;

– Ошибка MAE: 0;

– Ошибка MAPE: 3.235;

– Ошибка MSE: 0.247;

– Ошибка RMSE: 0.497;

– Оценка R2 на тестовой выборке: 0.758.

Графическое сравнение данных представлено на рисунке 15.

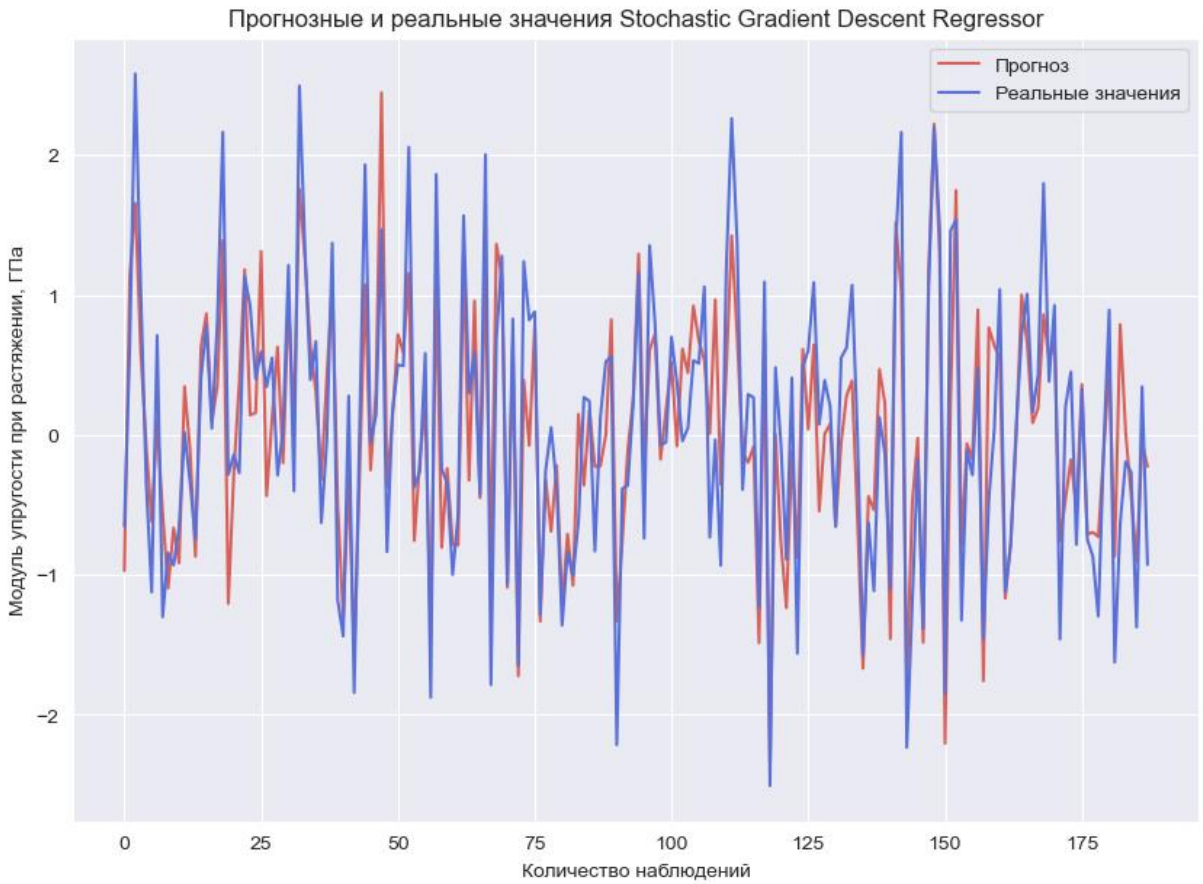


Рисунок 15 – Прогнозные и реальные значения модуля упругости при растяжении

Распределение ошибки модели представлено на рисунке 16.

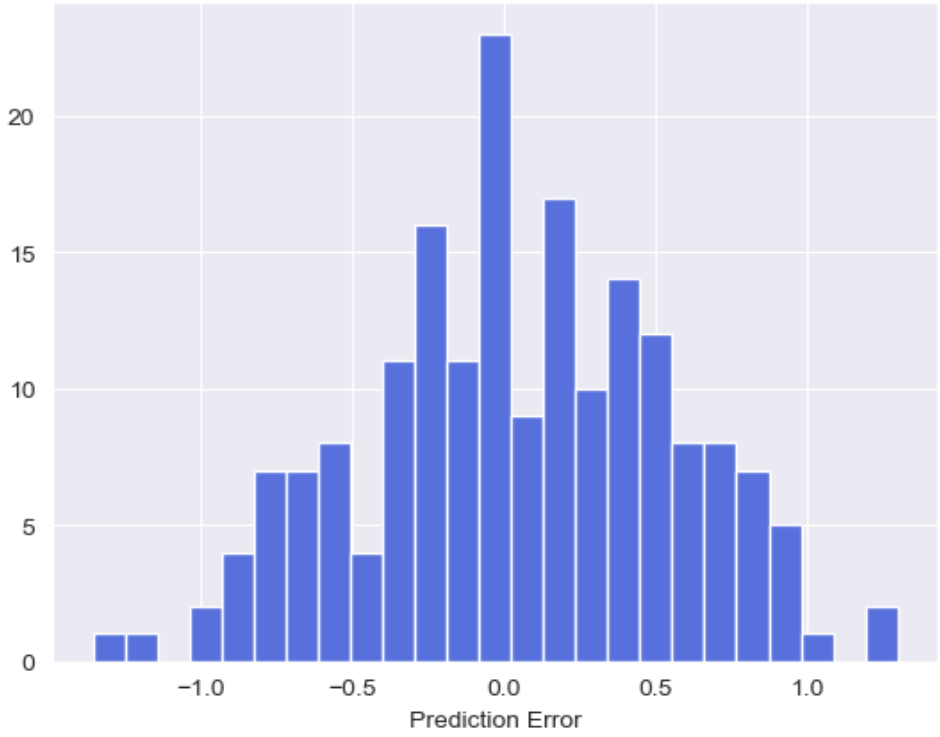


Рисунок 16 – Распределение ошибки SGDRegressor

2) Определение прочности при растяжении:

– Модель: SVR;

– Лучшие гиперпараметры: kernel='linear', gamma='auto', C=500, epsilon=0.01;

– Оценка R2 при перекрестной проверке: 0,864;

– Оценка R2 после обучения: 0,870;

– Оценка MAE: 0;

– Оценка MAPE: 0.757;

– Оценка MSE: 0.119;

– Оценка RMSE: 0.345;

– Оценка R2 на тестовой выборке: 0.882.

Графическое сравнение данных представлено на рисунке 17.

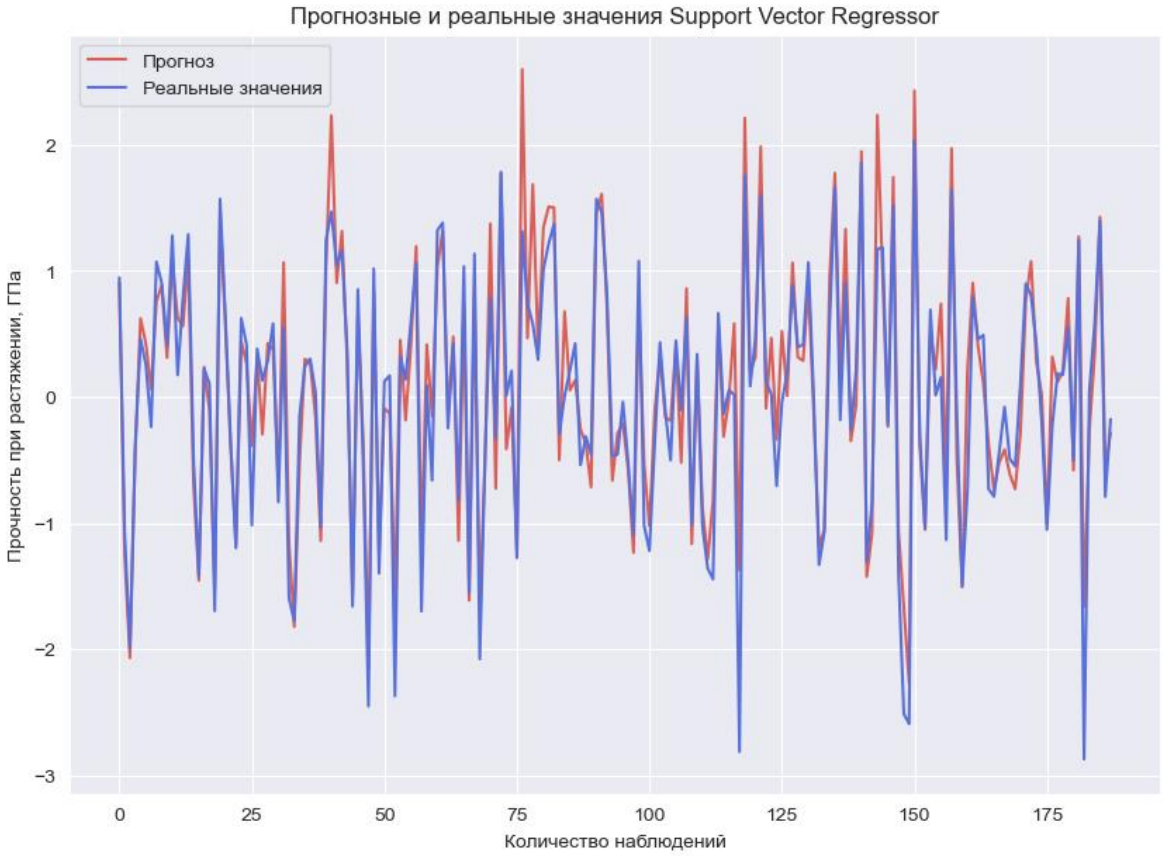


Рисунок 17 – Прогнозные и реальные значения прочности при растяжении

Распределение ошибки модели представлено на рисунке 18.

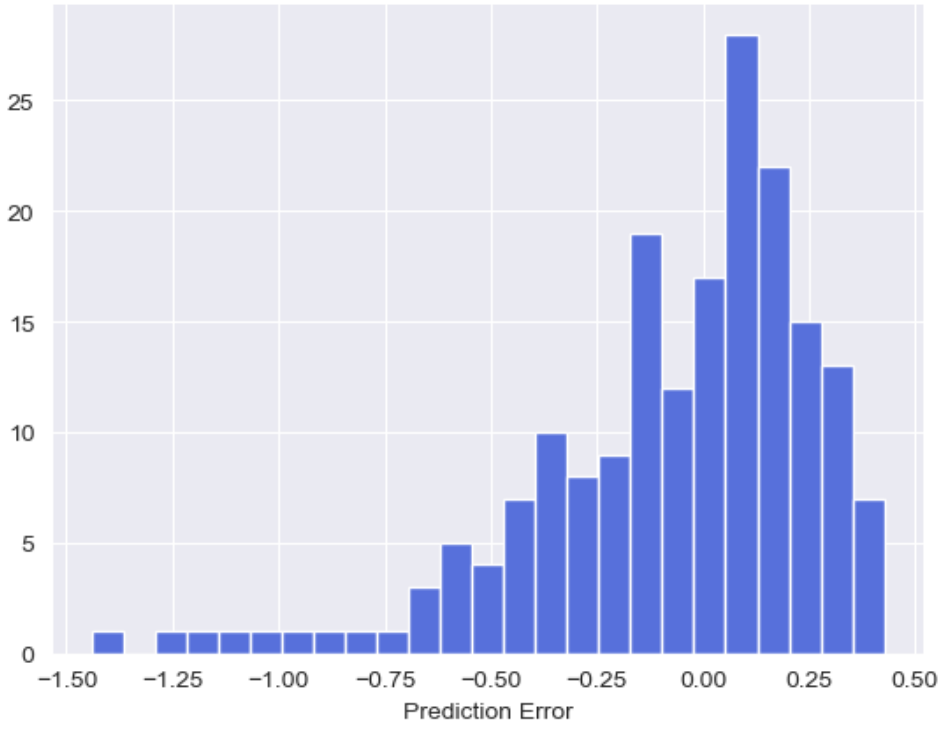


Рисунок 18 – Распределение ошибки SVR

2.4. Нейронная сеть для рекомендаций соотношения матрица-наполнитель

Для определения соотношения матрица-наполнитель разработана полносвязная нейронная сеть.

Архитектура сети представлена на рисунке 19.

```
Model: "sequential"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 layer_normalization (LayerN  (None, 6)                12
 ormalization)

 dense (Dense)               (None, 256)               1792

 dense_1 (Dense)             (None, 256)               65792

 dropout (Dropout)           (None, 256)               0

 dense_2 (Dense)             (None, 128)               32896

 dense_3 (Dense)             (None, 128)               16512

 dropout_1 (Dropout)         (None, 128)               0

 dense_4 (Dense)             (None, 64)                8256

 dense_5 (Dense)             (None, 64)                4160

 dropout_2 (Dropout)         (None, 64)                0

 dense_6 (Dense)             (None, 32)                2080

 dense_7 (Dense)             (None, 32)                1056

 dense_8 (Dense)             (None, 1)                 33

=================================================================
Total params: 132,589
Trainable params: 132,589
Non-trainable params: 0
_________________________________________________________________
None
```

Рисунок 19 – Архитектура нейронной сети

Для нейросети был произведен отбор переменных. Однако ни на полном наборе данных, ни с отобранными переменными нейросеть не обеспечила предсказание, что отображено на рисунке 20.

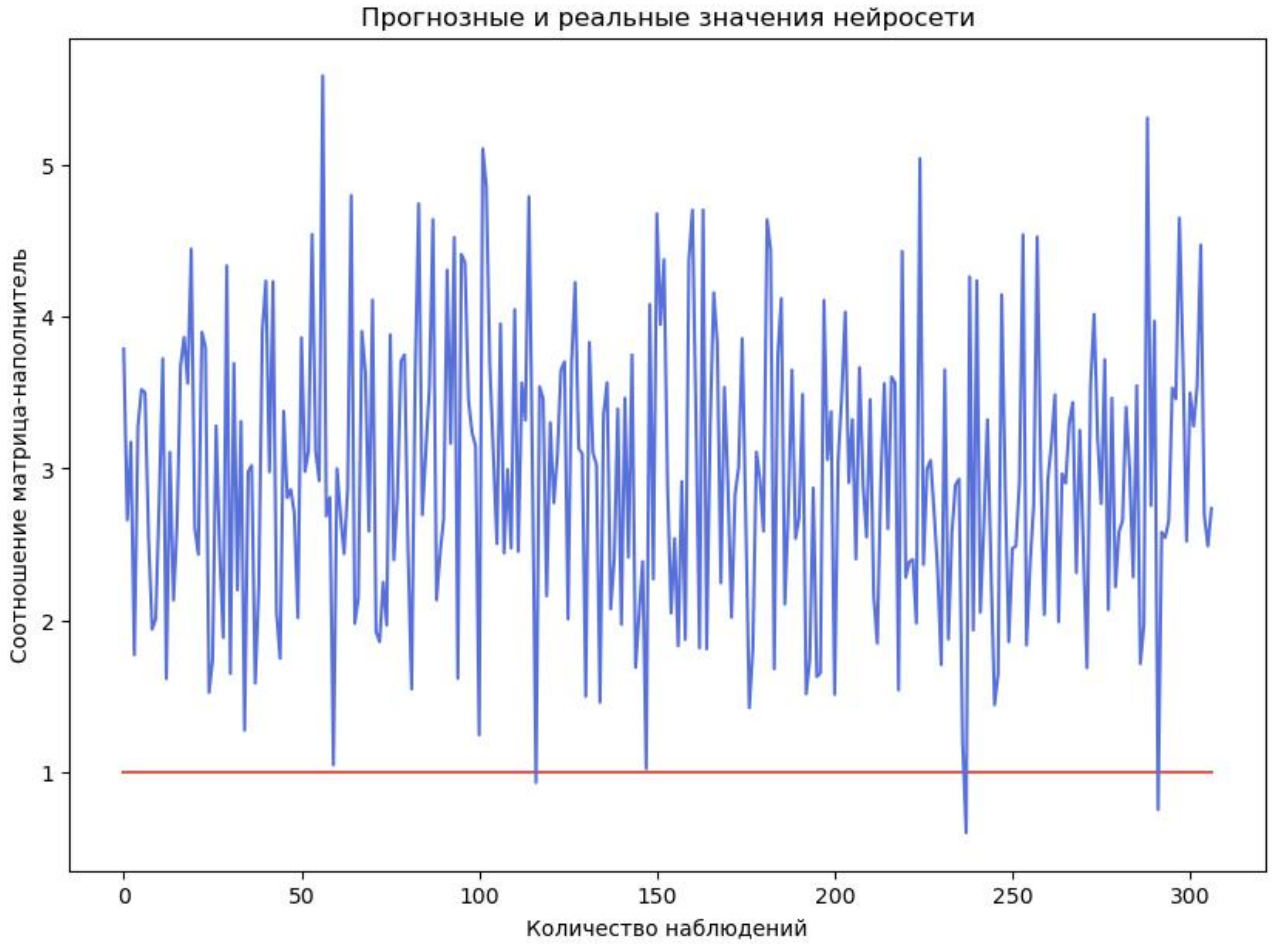


Рисунок 20 – Прогнозные и реальные значения соотношения матрица-наполнитель

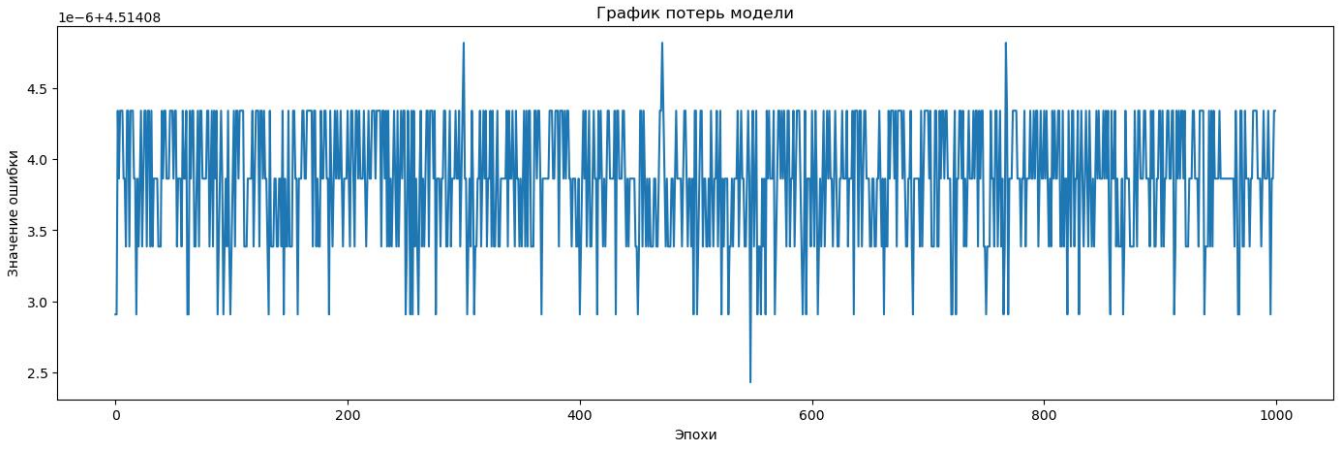


Рисунок 21 – График функции потерь

3. Вывод

Работа с данным датасетом была интересной и даже захватывающей. Однако вопросу подготовки данных для нейросети и подбору параметров нейросети нужно было уделить времени больше, чем у меня было на текущий момент. Считаю, что нет данных на которых не сможет работать какой-либо алгоритм, иногда бывает существенный недостаток ресурсов. Задача отличная и весьма интересная.